

proof

@闫朝阳 2022.03.28

定义输入矩阵为 $X_{m \times n}$, m 为维度, n 为样本;

对 $X_{m \times n}$ 进行 Kernel PCA 分析, 即等价于, 将 $X_{m \times n}$ 映射到高维空间得到 $F_{d \times n} (d \gg m)$ 对其进行 PCA 分析。

记: $F = \varphi(X)$ 为由 X 到 F 的映射函数。而往往, $\varphi()$ 和 F 不可知。因此, 对于高维空间的 $F_{d \times n}$ 的样本间内积 $F \cdot F^T$ 难以计算, 此时, 设定义核函数 $k(x, y) = \varphi(x) * \varphi(y)'$, 表示 X 映射到高维空间的内积, 可直接由 X 应用核函数等价。

即, 核函数 $k(X)$ 确定核矩阵 $K_{n \times n}$, 等价于 $F^T \cdot F$ 。

此时, 对 $F_{d \times n}$ 进行 PCA,

假设 $F_{d \times n}$ 已中心化,

则协方差矩阵 $D_{d \times d} = \frac{1}{n} F_{d \times n} \cdot F_{n \times d}^T$ [1], $D_{d \times d}$ 为实对称矩阵, 有性质:

$D_{d \times d}$ 可被对角化, 且有 $U^T \cdot D_{d \times d} \cdot U = \Lambda$, 其中 Λ 为对角元素为 $D_{d \times d}$ 特征值组成的对角矩阵; $U_{d \times d}$ 每一列为特征值对应的特征向量;
其中, $D_{d \times d}$ 求特征值特征向量可以表示为: $D \cdot U = \lambda U$ [2]。

我们知道, 对 $F_{d \times n}$ 进行 PCA, 即求协方差矩阵 $D_{d \times d}$ 的前 k 个特征向量按行组成的矩阵 $P_{k \times d}$ 使得 $P_{k \times d} \cdot F_{d \times n} = \dot{F}_{k \times n}$ [3];

此时 $\dot{F}_{k \times n}$ 是我们希望的输出;

由 PCA 可知 (这里对 PCA 不做讨论),

即, $P_{k \times d}$ 等于上述前 k 特征值对应的特征向量组成的矩阵, 即矩阵 U 的前 k 列的转置矩阵, $U_{k \times d}^T$,

即, $U_{k \times d}^T \cdot F_{d \times n} = \dot{F}_{k \times n}$ [4]

此时, 联立 [1, 2] 式:

$D \cdot U = \lambda U$,

即, $\frac{1}{n} F_{d \times n} \cdot F_{n \times d}^T \cdot U = \lambda U$,

两边左乘 F^T 矩阵,

则, $\frac{1}{n} F^T \cdot F \cdot F^T \cdot U = \lambda F^T \cdot U$,

将 $F^T \cdot F$ 视作整体,

即, $(F^T \cdot F) \cdot (F^T \cdot U) = n \lambda (F^T \cdot U)$,

显然, $F^T \cdot F$ 特征值为 $n \lambda$, 特征向量为 $F^T \cdot U$ [5],

而根据 [4] 式, 我们希望的输出是:

$\dot{F}_{k \times n} = U_{k \times d}^T \cdot F_{d \times n} = (F_{n \times d}^T \cdot U_{d \times k})^T$,

即, 为 [5] 式中 $F^T \cdot F$ 的前 k 个特征值对应的特征向量。

因此, 我们只需对 $F^T \cdot F$ 进行特征分解即可。

而 $F^T \cdot F$, 正是我们已知的核矩阵 $K_{n \times n}$ 。

解答2 与 KPCA

当前方案中,

workflow 先对输入矩阵 $X_{m \times n}$ 进行距离度量获得 dissimilarity matrix $M_{n \times n}$;

然后 workflow 对 $M_{n \times n}$ 标准化后得到 $\bar{M}_{n \times n}$, 我们假设由 X 到 \bar{M} 映射函数为 $\phi(x)$;

workflow 然后对 \bar{M} 进行 PCA 分析并获取其前 k 个主成分,

也就是，获取了 $\bar{M}_{n \times n}$ 的协方差矩阵 $T_{n \times n}$ 的前 k 个特征值对应的特征向量矩阵；我们形式化为：

$$T_{n \times n} = \frac{1}{n} \bar{M}_{n \times n} \cdot \bar{M}_{n \times n}^T [6],$$

将 $n \cdot T_{n \times n} = \bar{M}_{n \times n} \cdot \bar{M}_{n \times n}^T$ 可等价于上述核矩阵 $K_{n \times n}$ ，

则，以上做法形式上等价于对 X 进行 KPCA。

另外， $n \cdot T_{n \times n}$ 核矩阵为协方差矩阵，因此一定为半正定矩阵，([reference](#))，满足核函数 mercer 定理；因此核函数形式上等价；

Mercer 定理：任何半正定的函数都可以作为核函数。所谓半正定的函数 $f(x_i, x_j)$ ，是指拥有训练数据集 (x_1, x_2, \dots, x_n) ，我们定义一个矩阵的元素 $a_{ij} = f(x_i, x_j)$ ，这个矩阵是 $n \times n$ 的，如果这个矩阵是半正定的，那么 $f(x_i, x_j)$ 就称为半正定的函数。

但，这里 $\bar{M}_{n \times n}$ 已知，由 X 经 $\phi(x)$ 映射，并非向高维空间映射，因此，并不严格意义等价。

疑问

能否不经过 dissimilarity matrix 度量，而是直接获取到的就是核矩阵 K ，此时直接对核矩阵 K 进行特征分解即严格满足。或者说，我获取到的 dissimilarity matrix 不做协方差矩阵运算，而直接进行特征分解？

解答1 与 PCoA

PCoA 中，对 dissimilarity matrix 构建离差矩阵（实对称矩阵），该矩阵同样具有性质：

$$U^T \cdot D_{d \times d} \cdot U = \Lambda, \text{ 其中 } \Lambda \text{ 为对角元素为 } D_{d \times d} \text{ 特征值组成的对角矩阵； } U_{d \times d} \text{ 每一列为特征值对应的特征向量；即， } D_{d \times d} = U \cdot \Lambda \cdot U^T$$

$$\text{进而， } D_{d \times d} = U \cdot \Lambda \cdot U^T = U \cdot \Lambda^{\frac{1}{2}} \Lambda^{\frac{1}{2}} \cdot U^T,$$

$C = \Lambda^{\frac{1}{2}} \cdot U^T$ 即为坐标矩阵；即取前 k 个特征值对应的特征向量按行组成，并乘各自特征值的平方根，即为 PCoA 输出。

当前方案中，

workflow 先对输入矩阵 $X_{m \times n}$ 进行距离度量获得 dissimilarity matrix $M_{n \times n}$ ；

然后计算协方差矩阵 $T_{n \times n}$ ，等价于 PCoA 中获得离差矩阵；

然后对 $T_{n \times n}$ 进行特征分解获取前 k 个特征值对应特征向量，相当于 $C = U^T$ 而没有考虑特征值。

此外，有一点值得注意，workflow 中 dissimilarity matrix 送入 PCA 中之前经过了一次数据标准化，导致原本 dissimilarity matrix 的数据结构性被破坏了。也就不满足 PCoA 的输入形式。因此，从这两个角度理解下来，workflow 做法都不等价于 PCoA。